

Projet OA

SOUTENANCE - CHALLENGE MACHINE LEARNING

Fatima-Sarah-Philéas-Mathias-Najlaa-Kenza



1. INTRODUCTION


→ Objectif du challenge:

- Développer une IA capable de détecter automatiquement les défauts de soudure à partir d'images industrielles, avec un niveau de fiabilité compatible avec un usage réel.

→ Enjeux Trustworthy AI :

- Indiquer son niveau de confiance pour éviter les décisions risquées
- Reconnaître les images hors distribution (OOD)
- Rester robuste face aux variations réelles des données.

2. ARCHITECTURE DE LA SOLUTION



3. DETAILS TECHNIQUES



- Prétraitement des données : nettoyage, encodage, features
- Choix du ou des modèles et justification
- Stratégie de validation (cross-validation, split, etc.)
- Optimisation : hyperparamètres, gestion du temps de calcul
- Utilisation de techniques d'ensemble ou d'augmentation


Préprocessing

Model

Augmentation/Extension de model (incertitude - OOD)

EXPLORATION INITIALE DES DONNÉES


Répartition des attributs



C20



C33



STATS ET RISQUES DES DONNÉES

CLASS DISTRIBUTION

OK → 97,9% (2797)
KO → 2,1% (60)

WELDING-SEAMS

C102 : 39%
C33 : 39%
C20 : 22%

TEMPORAL RANGE

2019 → 2022

RESOLUTION

1920×1080 → 66%
960×540 → 34%

BLUR

CLEAN : 68,8%
BLUR : 31,2%
BLUR_LEVEL : 23 → 5 485

LUMINOSITY

RANGE : 13,7 → 56,3
MEAN : 43,4

RISQUES ET BIAIS :

BIAIS D'ACQUISITION

SURPERFORMANCE MODÈLE

SURREPRÉSENTATION
(C20 = 46,6% DES KO)

BIAIS DE CONTEXTE
(KO = 100% EXPERTS)

1. PRÉ-PROCESSING MODULE D'AUGMENTATION



Problème

- Déséquilibre : OK 98% / KO 2%
- Zones rares : blur >3000 , lum $<25/>55$

Solution

Augmentation réaliste adaptée au contexte industriel

Transformations :

- Flou variable (3-17px)
- Luminosité ($\pm 15-35\%$)
- Bruit gaussien
- Légères translations ($\pm 5\%$)

1. PRÉ-PROCESSING : DATALOADER

```
class ImageDataFrameBalancedDataset(Dataset):
    """
    Dataset PyTorch qui combine :
    - WeldinAugmentation (base, aggressive, rare_zones)
    - PyTorch transforms (jitter, blur, lumière)
    - Sur-échantillonnage KO et zones rares
    """
    def __init__(
        self,
        df: pd.DataFrame,
        root_dir: str | Path = ".",
        path_col: str = "path",
        label_col: str = "label",
        label_transform: Optional[Callable] = None,
        channels_first: bool = True,
        is_train: bool = True,
        welding_mode: str = "balanced"
    ):
```

- Dataloader pytorch
- Données pour l'entraînement et la validation
- Augmentation des données


But : Robustifier le modèle et réduire les biais.

IMPLÉMENTATION

```
# Créer les datasets
Train_Dataset = ImageDataFrameDataset(
    df=df_train,
    root_dir="./datasets/welding-detection-challenge-dataset/", # chemin racine
    path_col="path",
    label_col="label",
    transform=transform,
    channels_first=True,
    is_train=True,
    weldin_mode="balanced"
)

Val_Dataset = ImageDataFrameDataset(
    df=df_val,
    root_dir="./datasets/welding-detection-challenge-dataset/",
    path_col="path",
    label_col="label",
    transform=transform,
    channels_first=True,
    is_train=False
)
```

2. CHOIX DU MODÈLE EN FONCTION DU TYPE DE SOUDURE



```
Types de décisions : ['KO' 'OK']
Valeurs manquantes : 0
Types de soudure : ['expert' 'operator']
```

```
=== Entraînement modèle pour c20 ===
```

```
■ Training started...
```

```
Training: 100%|██████████| 73/73 [09:11<00:00, 7.56s/it, loss=0.191]
```

```
■ Epoch 1/1 | Train: 0.2083 | Val: 0.1141
```

```
📄 Best model updated → best_model_c20.pth
```

```
🏁 Training completed in 569.8s
```

```
=== Entraînement modèle pour c33 ===
```

```
■ Training started...
```

```
Training: 100%|██████████| 133/133 [17:15<00:00, 7.79s/it, loss=0.201]
```

```
■ Epoch 1/1 | Train: 0.0972 | Val: 0.0214
```

```
📄 Best model updated → best_model_c33.pth
```

```
🏁 Training completed in 1084.1s
```

```
=== Entraînement modèle pour c102 ===
```

```
■ Training started...
```

```
Training: 100%|██████████| 133/133 [19:35<00:00, 8.84s/it, loss=0.00526]
```

```
■ Epoch 1/1 | Train: 0.1026 | Val: 0.0304
```

```
📄 Best model updated → best_model_c102.pth
```

```
🏁 Training completed in 1196.1s
```

```
🎉 Entraînement des trois modèles terminé !
```

```
🔧 Loading Welding Quality AI Component...  
Missing keys (dans le modèle mais pas dans le checkpoint) : []  
Unexpected keys (dans le checkpoint mais pas dans le modèle) : []  
✅ Model weights loaded from C:\Users\phile\Documents\Cours\ING5\IA de confiance\Challenge\_welding\challenge\_solution\best\_model.pth  
🔧 Using CPU  
🔥 Model warmup completed  
✅ AI Component loaded on cpu  
  
♦ Image : ./datasets/welding-detection-challenge-dataset/c33/OK/expert/sample\_10.jpeg  
Modèle utilisé : c33  
Prediction : OK  
Probabilités : OK=0.990, KO=0.010, UNKNOWN=0.000  
OOD score : 0.000
```

✓ Performance accrue

Chaque modèle est optimisé pour un type de soudure précis → meilleure précision.

✓ Flexibilité

Facile d'ajouter un nouveau type de soudure

✓ Robustesse

Score OOD protège contre les images "hors distribution"

Détection d'anomalies ou erreurs de capture

✓ Scalabilité

Approche modulaire : les modèles sont indépendants.


Possibilité de les entraîner ou déployer séparément.

PROPOSITION D'UN NOUVEAU MODÈLE

DualPathWeldNet repose sur 2 branches :

Une branche locale → un CNN léger orienté micro-défauts ;

Une branche globale → avec des convolutions à grand kernel et un bloc Squeeze-and-Excitation pour ajouter un mécanisme d'attention canal.



20%	4/20	[00:20<01:20,	5.06s/it]4
25%	5/20	[00:26<01:18,	5.23s/it]5
30%	6/20	[00:30<01:08,	4.88s/it]6
35%	7/20	[00:35<01:05,	5.06s/it]7
40%	8/20	[00:40<01:00,	5.08s/it]8
45%	9/20	[00:46<00:56,	5.10s/it]9
50%	10/20	[00:52<00:55,	5.50s/it]10
55%	11/20	[00:57<00:47,	5.29s/it]11
60%	12/20	[01:01<00:40,	5.01s/it]12
65%	13/20	[01:07<00:36,	5.21s/it]13
70%	14/20	[01:11<00:30,	5.02s/it]14
75%	15/20	[01:16<00:24,	4.99s/it]15
80%	16/20	[01:25<00:26,	5.18s/it]16

3. EXTENSION DE MODÈLE

→ Objectif : Rendre le modèle plus robuste grâce à l'incertitude et OOD

Le modèle prédit toujours, même quand l'image est douteuse
Aucune notion de confiance → risque


→ Ajouter la quantification d'incertitude + la détection OOD

Impact : modèle plus sûr, transparent et fiable

INCERTITUDE :

On ajoute :

- MC Dropout (30 passes)
- 2 types d'incertitudes :
 - Épistémique (manque de données : seam c20)
 - Aléatoire (flou, faible luminosité)



Utilité :


- Identifier les images douteuses
- Repérer les zones critiques du dataset
- Réduire les erreurs en production

DETECTION OOD : Images anormales

OOD = images jamais vues à l'entraînement.

Méthodes ajoutées :


- Mahalanobis
- Isolation Forest
- Energy Scores



Objectif : repérer les images trop floues, trop sombres ou atypiques

Résultat :

- Détection robuste des cas dangereux
- Possibilité d'afficher UNKNOWN



2D Density Plot : Zones Rares du Dataset

- La masse de données est concentrée entre blur 500–2000 & luminosité 35–50.
- Les zones peu denses (blur > 3000, luminosité < 30) indiquent peu d'exemples.
- Ces zones créent naturellement incertitude & risque OOD interne.

4. ANALYSE DES PERFORMANCES



Pré-traitement



Multi modèle

- Flexibilité : Facile d'ajouter un nouveau type de soudure
- Performance : Chaque modèle est optimisé pour un type de soudure précis → meilleure précision.



Adaptation du modèle

- Détection robuste des cas dangereux
- Possibilité d'afficher UNKNOWN



Extension du modèle

- Ajouter la quantification d'incertitude + la détection OOD

5. CONCLUSION